

*작성 가이드	- 데이터셋의 국문명, 영문명 모두 필수기재 - 동일 과제에 속한 데이터셋의 소개 내용은 각 데이터셋의 특징을 알 수 있도록 내용을 차별화하여 작성할 것(동일 내용의 반복은 피할 것) - 내용에 삽입된 이미지는 .PNG 포맷(2배 크기)로 저장하여 원본 이미지는 별도 제출할 것 - 내용에 삽입된 표, 그래프 자료는 엑셀 파일에 정리하여 별도 제출 - 내용의 구축기관 정보에 프로젝트 참여 기업 정보는 누락 없이 모두 기재할 것 (주관 수행기관사 책임자명/전화번호/메일주소 등은 연결 가능한 정보로 기재할 것) - 아래 메타테이블에 데이터 관련 문의처 정보는 데이터 이용자들에 대한 기술지원이 가능한 기관의 실무 담당자를 지정하여 정보를 기재할 것. 문의시 담당자와 직접 연결이 가능한 정보로 기재 - 아래 메타테이블에 가공기관, 검수기관은 업무 담당 업체명은 누락 없이 모두 기재할 것 - 전화번호의 경우, 개인 휴대폰 전화번호가 아닌 회사유선번호를 기재해야 함(개인정보) - 한글파일(hwp)로 제출 - 카테고리 정의서는 지정엑셀양식에 데이터카테고리 작성하여 제출

메타테이블 정보 (다중기입가능)	분야	데이터 유형 ¹⁾	구축 데이터량	원천데이터 형식 ²⁾	라벨링 형식 ³⁾	라벨링 유형 ⁴⁾
	NIA 기입	텍스트	50,413건	txt	json	Annotation (에세이 종류, 주제, 학생, 학년, 난이도, Scoring(평가점수))
	데이터 출처 ⁵⁾	데이터 구축년도	구축기관(총괄)	가공기관	검수기관	
	자체수집	2021년	티맥스에이아이	유평	인터마인즈	
	데이터 문의처	기관명	문의담당자명	전화번호 (유선전화번호기입)	메일주소	
		티맥스에이아이	이상효	031-639-0603	sanghyo_lee@tmax.co.kr	
	데이터 소개	에세이 글 데이터는 선별된 주제(50가지)에 대하여 초/중/고 학생들의 글을 수집하고, 에세이 글 평가 기준을 확립함으로써, 에세이 자동 평가 모델 구축을 위한 데이터입니다.				
	주요키워드	초/중/고, 에세이 글쓰기, 에세이 글 평가, 글 자동 평가				
카테고리 정의서		첨부의 카테고리 정의서 엑셀파일에 데이터카테고리 작성하여 제출(예시참고)				

1) 텍스트, 오디오, 이미지, 비디오.
2) txt, jpg,.....
3) json, csv,.....
4) 내용요약(텍스트), 번역(자연어), 질의응답(자연어), 바운딩박스(이미지/동영상), 키포인트(이미지/동영상), 세그멘테이션(이미지/동영상), 전자(음성)
5) 4대 언론기사, 자체 수집.....

데이터셋명	국문영문	에세이 글 평가 데이터셋																																															
		Essay Scoring Dataset																																															
구축목적	에세이 글 데이터 확보를 통한 초/중/고 학생들의 인공지능 자동 평가 서비스 개발 및 문서인식 분야에 활용하기 위함																																																
활용서비스	개인 Essay 실력 평가 서비스, 대화 기반 평가(표현력, 구성력, 내용적절성) 서비스, 학교/학원 Essay 자동 평가 서비스																																																
소개	초등(고학년)·중학생·고등학생 비율, 교육과정을 고려한 주제·타입·난이도, 평균 분량 등 편향되지 않은 dataset으로, 2가지 타입(논술/수필)과 5가지 세부타입(주장/찬·반/대안제시/설명글/글짓기)의 50개의 주제로 구분하여 데이터의 다양성을 추구하며 원천데이터를 확보 단순히 Essay 전체에 대한 Scoring만 되어있는 기존 AES 분야 학습데이터 보다 Essay 전체, 문단, 교정문장, 문법, 맞춤법 등 구체적 기준을 바탕으로 데이터를 구축하여, 개인 Essay 실력에 대한 평가 및 피드백이 가능 데이터 수집환경 데이터 수집, 가공 데이터 정제 AI 모델링 응용서비스 개발																																																
	1. 데이터 구축 규모 <table><tr><th colspan="2">데이터 종류</th><th>개수</th></tr><tr><td colspan="2">원시 데이터</td><td>약 60,000건</td></tr><tr><td colspan="2">원천 데이터</td><td>약 50,000건</td></tr><tr><td colspan="2">라벨 데이터</td><td>약 50,000건</td></tr><tr><td>채점 라벨 포함</td><td></td><td>약 50,000건</td></tr><tr><td>교정 라벨 포함</td><td></td><td>약 10,000건</td></tr></table> - 손실/오류가 있는 데이터를 제외한 고품질의 라벨 데이터 50,000건 수집 - 라벨 데이터에는 채점 라벨이 모두 포함되어 있음 - 라벨 데이터 가운데 10,000건에 교정 라벨이 포함되어 있음 ※ 초등, 중등, 고등 학년에 따른 데이터 수량 <table><tr><th>학교</th><th>학년</th><th>개수</th><th>학교</th><th>학년</th><th>개수</th><th>학교</th><th>학년</th><th>개수</th></tr><tr><td rowspan="3">초등 (39%)</td><td>4학년</td><td>7,800건</td><td rowspan="3">중등 (38%)</td><td>1학년</td><td>7,800건</td><td rowspan="3">고등 (23%)</td><td>1학년</td><td>6,000건</td></tr><tr><td>5학년</td><td>7,800건</td><td>2학년</td><td>7,800건</td><td>2학년</td><td>6,000건</td></tr><tr><td>6학년</td><td>7,800건</td><td>3학년</td><td>7,200건</td><td>3학년</td><td>2,000건</td></tr></table>		데이터 종류		개수	원시 데이터		약 60,000건	원천 데이터		약 50,000건	라벨 데이터		약 50,000건	채점 라벨 포함		약 50,000건	교정 라벨 포함		약 10,000건	학교	학년	개수	학교	학년	개수	학교	학년	개수	초등 (39%)	4학년	7,800건	중등 (38%)	1학년	7,800건	고등 (23%)	1학년	6,000건	5학년	7,800건	2학년	7,800건	2학년	6,000건	6학년	7,800건	3학년	7,200건	3학년
데이터 종류		개수																																															
원시 데이터		약 60,000건																																															
원천 데이터		약 50,000건																																															
라벨 데이터		약 50,000건																																															
채점 라벨 포함		약 50,000건																																															
교정 라벨 포함		약 10,000건																																															
학교	학년	개수	학교	학년	개수	학교	학년	개수																																									
초등 (39%)	4학년	7,800건	중등 (38%)	1학년	7,800건	고등 (23%)	1학년	6,000건																																									
	5학년	7,800건		2학년	7,800건		2학년	6,000건																																									
	6학년	7,800건		3학년	7,200건		3학년	2,000건																																									

2. 데이터 분포

항목명	측정 지표	정량 목표																																															
학년교별 분포	비율	초등 39% 중등 38% 고등 23%																																															
학년별 분포	비율	초등 4, 5, 6 각 약 13% 중등 1, 2, 3 각 약 13% 중등 3 약 12% 고등 1, 2, 3 각 약 10% 고등 3 약 3.3%																																															
난이도별 분포	수준	- 학교별로 에세이 주제를 상, 중, 하 난이도 구분																																															
		<table><tr><th>학교</th><th>난이도</th><th>주제 개수 (개)</th><th>학교별 백분율 (%)</th></tr><tr><td rowspan="4">초등</td><td>상</td><td>1</td><td>6</td></tr><tr><td>중</td><td>9</td><td>50</td></tr><tr><td>하</td><td>8</td><td>44</td></tr><tr><td>총계</td><td>18</td><td>100</td></tr><tr><td rowspan="4">중등</td><td>상</td><td>2</td><td>11</td></tr><tr><td>중</td><td>12</td><td>67</td></tr><tr><td>하</td><td>4</td><td>22</td></tr><tr><td>총계</td><td>18</td><td>100</td></tr><tr><td rowspan="4">고등</td><td>상</td><td>5</td><td>36</td></tr><tr><td>중</td><td>8</td><td>57</td></tr><tr><td>하</td><td>1</td><td>7</td></tr><tr><td>총계</td><td>14</td><td>100</td></tr><tr><td colspan="2">총계</td><td>50</td><td>-</td></tr></table>	학교	난이도	주제 개수 (개)	학교별 백분율 (%)	초등	상	1	6	중	9	50	하	8	44	총계	18	100	중등	상	2	11	중	12	67	하	4	22	총계	18	100	고등	상	5	36	중	8	57	하	1	7	총계	14	100	총계		50	-
		학교	난이도	주제 개수 (개)	학교별 백분율 (%)																																												
		초등	상	1	6																																												
			중	9	50																																												
			하	8	44																																												
			총계	18	100																																												
		중등	상	2	11																																												
			중	12	67																																												
			하	4	22																																												
			총계	18	100																																												
		고등	상	5	36																																												
			중	8	57																																												
			하	1	7																																												
			총계	14	100																																												
총계		50	-																																														
Type별 분포	비율	<table><tr><td rowspan="3">논술형 (51.5%)</td><td>주장 (21.93%)</td></tr><tr><td>찬/반 (16.11%)</td></tr><tr><td>대안제시 (13.46%)</td></tr><tr><td>수필형 (48.5%)</td><td>설명글 (37.04%)</td></tr><tr><td></td><td>글짓기 (11.46%)</td></tr></table>	논술형 (51.5%)	주장 (21.93%)	찬/반 (16.11%)	대안제시 (13.46%)	수필형 (48.5%)	설명글 (37.04%)		글짓기 (11.46%)																																							
		논술형 (51.5%)		주장 (21.93%)																																													
				찬/반 (16.11%)																																													
			대안제시 (13.46%)																																														
수필형 (48.5%)	설명글 (37.04%)																																																
	글짓기 (11.46%)																																																
에세이 글 길이 분포	비율	- 에세이 주제마다 최소음절수 및 최대 음절수가 존재(이 때 최대 음절수는 1500으로 모두 같다) - 에세이 주제마다 에세이의 음절수 분포를 확인 - 주제별 최소 음절수																																															

		<table><tr><th>최소음절수(개)</th><th>주제(개)</th><th>에세이 개수(%)</th></tr><tr><td>200</td><td>4</td><td>8.64</td></tr><tr><td>250</td><td>5</td><td>10.80</td></tr><tr><td>300</td><td>8</td><td>17.28</td></tr><tr><td>350</td><td>4</td><td>8.64</td></tr><tr><td>400</td><td>6</td><td>12.96</td></tr><tr><td>450</td><td>2</td><td>3.99</td></tr><tr><td>500</td><td>8</td><td>14.78</td></tr><tr><td>600</td><td>7</td><td>12.62</td></tr><tr><td>650</td><td>4</td><td>6.98</td></tr><tr><td>700</td><td>2</td><td>3.32</td></tr></table>	최소음절수(개)	주제(개)	에세이 개수(%)	200	4	8.64	250	5	10.80	300	8	17.28	350	4	8.64	400	6	12.96	450	2	3.99	500	8	14.78	600	7	12.62	650	4	6.98	700	2	3.32																		
최소음절수(개)	주제(개)	에세이 개수(%)																																																			
200	4	8.64																																																			
250	5	10.80																																																			
300	8	17.28																																																			
350	4	8.64																																																			
400	6	12.96																																																			
450	2	3.99																																																			
500	8	14.78																																																			
600	7	12.62																																																			
650	4	6.98																																																			
700	2	3.32																																																			
학교 난이도별 평균 음절수 분포	비율	<table><tr><th colspan="4">학교 난이도별로 평균 음절수 분포</th></tr><tr><th>학교</th><th>난이도</th><th>에세이 개수</th><th>평균 음절수</th></tr><tr><td rowspan="3">초등</td><td>상</td><td>950</td><td>408</td></tr><tr><td>중</td><td>8,200</td><td>442</td></tr><tr><td>하</td><td>6,921</td><td>362</td></tr><tr><td rowspan="3">중등</td><td>상</td><td>673</td><td>756</td></tr><tr><td>중</td><td>5,299</td><td>600</td></tr><tr><td>하</td><td>1,623</td><td>548</td></tr><tr><td rowspan="3">고등</td><td>상</td><td>877</td><td>1,000</td></tr><tr><td>중</td><td>2,379</td><td>876</td></tr><tr><td>하</td><td>1,252</td><td>811</td></tr></table>	학교 난이도별로 평균 음절수 분포				학교	난이도	에세이 개수	평균 음절수	초등	상	950	408	중	8,200	442	하	6,921	362	중등	상	673	756	중	5,299	600	하	1,623	548	고등	상	877	1,000	중	2,379	876	하	1,252	811													
학교 난이도별로 평균 음절수 분포																																																					
학교	난이도	에세이 개수	평균 음절수																																																		
초등	상	950	408																																																		
	중	8,200	442																																																		
	하	6,921	362																																																		
중등	상	673	756																																																		
	중	5,299	600																																																		
	하	1,623	548																																																		
고등	상	877	1,000																																																		
	중	2,379	876																																																		
	하	1,252	811																																																		
지역별 분포	비율	<table><tr><th colspan="3">지역별 분포표</th></tr><tr><th>지역</th><th>개수 (개)</th><th>백분율(%)</th></tr><tr><td>서울특별시</td><td>351</td><td>1.3</td></tr><tr><td>경기도</td><td>953</td><td>3.3</td></tr><tr><td>인천광역시</td><td>448</td><td>1.5</td></tr><tr><td>강원도</td><td>388</td><td>1.3</td></tr><tr><td>충청남도</td><td>618</td><td>2.1</td></tr><tr><td>대전광역시</td><td>15,246</td><td>52.3</td></tr><tr><td>부산광역시</td><td>68</td><td>0.2</td></tr><tr><td>울산광역시</td><td>211</td><td>0.8</td></tr><tr><td>대구광역시</td><td>1,695</td><td>5.8</td></tr><tr><td>경상북도</td><td>1</td><td>0.0</td></tr><tr><td>경상남도</td><td>135</td><td>0.5</td></tr><tr><td>전라남도</td><td>8,860</td><td>30.4</td></tr><tr><td>광주광역시</td><td>139</td><td>0.5</td></tr><tr><td>전라북도</td><td>3</td><td>0.0</td></tr><tr><td>총계</td><td>29,116</td><td>100</td></tr></table>	지역별 분포표			지역	개수 (개)	백분율(%)	서울특별시	351	1.3	경기도	953	3.3	인천광역시	448	1.5	강원도	388	1.3	충청남도	618	2.1	대전광역시	15,246	52.3	부산광역시	68	0.2	울산광역시	211	0.8	대구광역시	1,695	5.8	경상북도	1	0.0	경상남도	135	0.5	전라남도	8,860	30.4	광주광역시	139	0.5	전라북도	3	0.0	총계	29,116	100
지역별 분포표																																																					
지역	개수 (개)	백분율(%)																																																			
서울특별시	351	1.3																																																			
경기도	953	3.3																																																			
인천광역시	448	1.5																																																			
강원도	388	1.3																																																			
충청남도	618	2.1																																																			
대전광역시	15,246	52.3																																																			
부산광역시	68	0.2																																																			
울산광역시	211	0.8																																																			
대구광역시	1,695	5.8																																																			
경상북도	1	0.0																																																			
경상남도	135	0.5																																																			
전라남도	8,860	30.4																																																			
광주광역시	139	0.5																																																			
전라북도	3	0.0																																																			
총계	29,116	100																																																			
평가지표별 분포	비율	- 각 평가지표마다의 점수 가중치는 아래 표와 같다. <table><tr><th></th><th>표현</th><th>구성</th><th>내용</th></tr><tr><td>논술 (51.5%)</td><td>3</td><td>3</td><td>4</td></tr><tr><td>수필 (48.5%)</td><td>4</td><td>2</td><td>4</td></tr></table>		표현	구성	내용	논술 (51.5%)	3	3	4	수필 (48.5%)	4	2	4																																							
	표현	구성	내용																																																		
논술 (51.5%)	3	3	4																																																		
수필 (48.5%)	4	2	4																																																		

1. 대표도면

<원시데이터 예시>		<평가표 예시>

2. 라벨링데이터 구성

구분	항목명	타입	필수여부	설명	범위	비고
1	info	object	Y	에세이 기본 정보		
	1.1 essay_id	string	Y	에세이 아이디		
	1.2 essay_type	string	Y	에세이 유형	불정 참고	
	1.3 essay_main_subject	string	Y	에세이 주제	불정 참고	
	1.4 essay_level	string	Y	에세이 난이도	불정 참고	
	1.5 essay_prompt	string	Y	에세이 프롬프트	불정 참고	
	1.6 essay_len	number	Y	에세이 글자수	1-1500	
2	student	object	Y	에세이 작성자 정보		
	2.1 student_grade_group	string	Y	학생 학년군	불정 참고	
	2.2 student_grade	string	Y	학생 학년	불정 참고	
	2.3 student_reading	number	Y	학생이 읽은 책의 양	불정 참고	
	2.4 student_educated	boolean	Y	학생의 논술 사고력 유무	불정 참고	
	2.5 student_school	string	Y	학생의 소속 학교	1-99999	
	2.6 date	string	Y	에세이 수집일		
	2.7 location	string	Y	에세이 수집 장소	불정 참고	
3	paragraph	array	Y	에세이 문단별 정보 목록		
	3.1 paragraph_id	string	Y	문단 아이디		
	3.2 paragraph_len	number	Y	문단 글자수	1-99999	
	3.3 paragraph_txt	string	Y	문단 텍스트	1-99999	
4	score	object	Y	에세이 점수 정보		
	4.1 essay_scoreT	array	Y	3명의 평가자 에세이 총점 목록	3-3	
	4.2 essay_scoreT_avg	number	Y	3명의 평가자 에세이 총점 평균	0-30	
	4.3 essay_scoreT_detail	object	Y	항목별 세부 정보		
	4.3.1 essay_scoreT_exp	array	Y	3명의 평가자별 전체 표현 점수 목록	0-3	
	4.3.2 essay_scoreT_org	array	Y	3명의 평가자별 전체 구성 점수 목록	0-3	
	4.3.3 essay_scoreT_cont	array	Y	3명의 평가자별 전체 내용 점수 목록	0-3	

4.4	paragraph_score	array	Y	문단별 점수 정보	1-99999	
4.4.1	paragraph_id	string	Y	문단 아이디		
4.4.1	paragraph_scoreT	array	Y	3명의 평가자 문단 총점 목록	3-3	
4.4.2	paragraph_scoreT_avg	number	Y	3명의 평가자 문단 총점 평균	0-3	
4.4.3	paragraph_scoreT_detail	object	Y	문단 항목별 세부 정보		
4.4.3.1	paragraph_scoreT_exp	array	Y	3명의 평가자별 문단 표현 점수 목록	0-3	
5	correction	array		에세이 교정 정보	0-999999	
5.1	sentence_id	string		문장 아이디		
5.2	sentence_txt	string		문 텍스트	0-999999	
5.3	sentence_corr_txt_grammar	string		문법 교정된 텍스트	0-999999	
5.4	sentence_corr_txt_styling	string		스타일링 교정된 텍스트	0-999999	
5.5	sentence_corr_type	array		교정 유형 목록	불정 참고	
5.6	sentence_corr_detail_type	array		교정 세부 유형 목록	불정 참고	
5.7	sentence_corr_reason	array		교정 이유 코멘트 목록	0-999999	
5.8	sentence_annotation_tag	string		어노테이션 태그	불정 참고	
5.9	paragraph_id	string		문단 식별자		
6	rubric	object	Y	루브릭 정보		
6.1	essay_type	string	Y	에세이 유형	불정 참고	
6.2	essay_main_subject	string	Y	에세이 주제	불정 참고	
6.3	essay_grade	string	Y	에세이 작성자 학년	불정 참고	
6.4	expression_weight	object	Y	루브릭 표현 가중치 정보		
6.4.1	exp	number	Y	대분류 표현 가중치	0-10	
6.4.2	exp_grammar	number	Y	문법 가중치	0-10	
6.4.3	exp_vocab	number	Y	단어 가중치	0-10	
6.4.4	exp_style	number	Y	문장표현 가중치	0-10	
6.5	organization_weight	object	Y	루브릭 구성 가중치 정보		
6.5.1	org	number	Y	대분류 구성 가중치	0-10	
6.5.2	org_essay	number	Y	문단 간 가중치	0-10	
6.5.3	org_paragraph	number	Y	문단 내 가중치	0-10	
6.5.4	org_coherence	number	Y	일관성 가중치	0-10	
6.5.5	org_quantity	number	Y	문량 가중치	0-10	
6.6	content_weight	object	Y	루브릭 내용 가중치		

6.6.1	con	number	Y	대분류 내용 가중치	0-10	
6.6.2	con_dearance	number	Y	주제 명료성 가중치	0-10	
6.6.3	con_novelty	number	Y	창신성 가중치	0-10	
6.6.4	con_prompt	number	Y	프롬프트 독해력 가중치	0-10	
6.6.5	con_description	number	Y	선술력 가중치	0-10	

3 라벨링데이터 실제예시

```
{
  "paragraph": [
    {
      "paragraph_txt": "내가 평소에 피아노에 관심이 많아 sns를 둘러보다 이 ...",
      "paragraph_len": 1033,
      "paragraph_id": "001"
    }
  ],
  "score": {
    "paragraph_score": [
      {
        "paragraph_scoreT": 2.777777,
        "paragraph_scoreT_detail": {
          "paragraph_scoreT_exp": [
            [3, 3, 2],
            [3, 3, 2],
            [2, 3, 3]
          ]
        }
      }
    ]
  },
  "essay_scoreT": 25.555555,
  "essay_scoreT_detail": {
    "essay_scoreT_org": [
      [3, 2, 2, 1],
      [3, 2, 3, 2],
      [2, 2, 2, 3]
    ],
    "essay_scoreT_cont": [
      [2, 2, 2, 0],
      [3, 2, 2, 0],
      [3, 3, 3, 0]
    ],
    "essay_scoreT_exp": [
      [3, 3, 2],
      [3, 3, 2],
      [2, 3, 3]
    ]
  }
}
```

```
{
  "paragraph": [
    {
      "paragraph_txt": "내가 평소에 피아노에 관심이 많아 sns를 둘러보다 이 ...",
      "paragraph_len": 1033,
      "paragraph_id": "001"
    }
  ],
  "score": { ...
  },
  "correction": {
    "sentence_corr_reason": ["특정 맞춤법이 약합니다"],
    "sentence_corr_txt": ["제가 피아노를 좋아하는 이유는 제 삶을 풍요롭게하기 때문입니다."],
    "sentence_id": "0001",
    "sentence_annotation_tag": "주제",
    "sentence_corr_type": ["문법"],
    "sentence_corr_detail_type": ["맞춤법"],
    "sentence_txt": "제가 피아노를 좋아하는 이유는 제 삶을 풍요롭게하기 때문입니다.",
    "paragraph_id": "001"
  }
}
```

데이터셋 구축 수행기관 담당자	주관기관	기관명	책임자명	전화번호 (유선전화번호가입)	메일주소	담당업무
		티맥스에이아이	황선웅	031-8018-9399	sunwoong_hwang@tmax.co.kr	PM
	참여기관	기관명	담당업무	기관명	담당업무	
		교육다움	초중 데이터수집	유허	고등데이터수집, 가공	
		에듀테크산업협회	데이터 정제	세명소프트	데이터 정제	
		인터마인즈	데이터 검수			